Semi-Supervised
Flower Classfication Report

一、 前言與目標

本次 lab 的目標是挑戰一個半監督式的花卉影像分類任務。在僅有 1200 張已標註影像和 1202 張未標註影像的條件下，我們需要從零開始（不可使用預訓練模型）打造一個深度學習模型，對五種花卉（daisy, dandelion, rose, sunflower, tulip）進行分類。這份報告將詳細闡述從模型初版建立、實驗迭代、瓶頸克服，至最終達成目標的完整技術路線與心路歷程。

二、 實驗方法與模型迭代歷程

經歷了多次模型架構的探索、訓練策略的優化，以及半監督學習方法的精細調校。整個歷程大致可分為以下幾個關鍵階段：

階段 1：以 ResNet-50 建立基準模型 (0.87272)

初期，我選擇了經典且效能卓越的 ResNet-50 作為基礎架構。鑑於訓練資料量有限，防止過擬合與提升模型泛化能力成為首要挑戰。為此，導入了多種訓練策略：

- **Data Augmentation**：除了常規的翻轉與裁切，我進一步採用了 RandAugment 進行自動化的策略搜尋，並結合 RandomErasing (Cutout) 來模擬影像遮擋，極大化了訓練資料的多樣性。
- **影像混合正規化 (Mixup / CutMix)**：在訓練迴圈中，我以 50% 的機率對每個批次的影像進行 Mixup 或 CutMix 處理。此舉強迫模型學習特徵之間的線性關係，有效抑制了模型對單一特徵的過度依賴。
- **優化策略**：選擇了帶有權重衰減修正的 AdamW 優化器，搭配 CosineAnnealingLR 學習率排程器，並在損失函數中引入 label_smoothing，以防止模型在分類時過度自信。

成果與分析： 此組合策略取得了 **87.27%** 的驗證集準確率，奠定了基礎。從訓練曲線圖(TABLE I)中可以觀察到一個非常健康的現象：橘色的驗證集準確率曲線（val）一路緊隨甚至超越了劇烈震盪的藍色訓練集準確率曲線（train)。這

明確地指出，正規化策略非常成功，**模型完全沒有發生過擬合**，並且學到了具有高度泛化性的特徵。

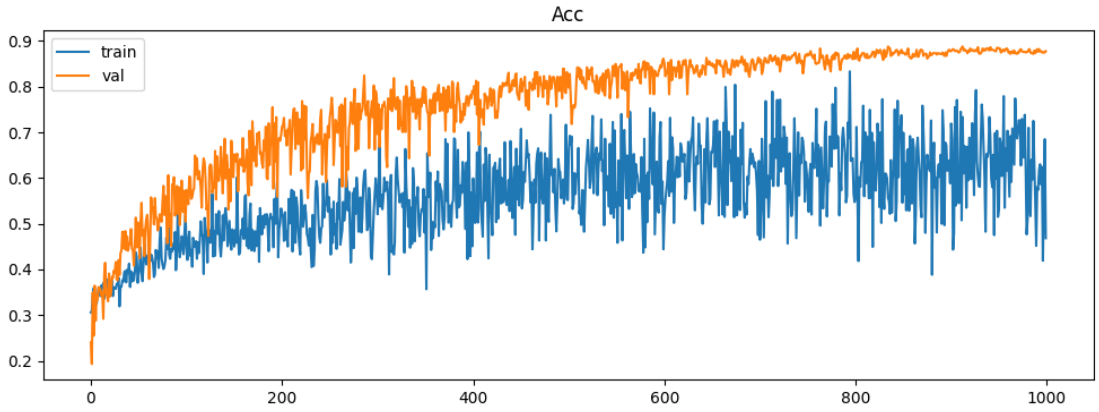

TABLE Ⅰ : ResNet-50 模型之訓練與驗證準確率曲線

階段 2：探索期 - ConvNeXt 與「過擬合」的教訓

為了尋求突破 90%準確度，我嘗試將模型更換為更現代的 ConvNeXtTiny 架構，期望其設計能帶來效能提升。然而，這次實驗卻讓我直接面對了小樣本學習中最經典的挑戰：「**過擬合 (Overfitting)**」。

- **遭遇的困難**：在一次旨在測試純模型效能的實驗中，我發現模型的驗證集準確率在約 250 個 epoch 後便停滯在 77% 左右不再提升，但訓練集準確率卻持續攀升至 80% 以上。從損失曲線圖來看，驗證集損失停止下降，而訓練集損失持續探底，這是典型的過擬合信號。
- **心得與反思**：它讓我深刻體會到「**沒有絕對最好的模型，只有最適合當前任務與資料的模型**」。對於這個僅有 1200 張標註圖片的小資料集，ResNet 經典的卷積結構及其歸納偏好，顯然比借鑒 Transformer 設計的 ConvNeXtTiny 更具優勢。這次的彎路雖然沒有直接提升成績，卻讓我堅定了回歸 ResNet 架構並將其潛力挖掘到極致的決心。

最終版 (V2): ResNet-34 (準確率: 0.926)

在確定了 ResNet 是正確的方向後，我決定集所有成功經驗之大成，打造一個最終的模型 。

階段一：最佳 Baseline (監督式學習，Acc Peak: 0.920)

這個階段的目標，是在半監督學習開始前，先打造一個無可挑剔的

baseline 模型。

- **模型架構**：最終我選擇了比 ResNet-50 稍輕量、但在此任務上被證明有效的 **ResNet-34** 架構。
- **訓練策略升級**：
  1. **資料增強**：我回歸了之前最成功的那套數據。特別是將 RandomResizedCrop 的 scale 保持在 (0.6, 1.0)，確保花的主體不會在裁切中遺失；同時使用較溫和的 ColorJitter，避免改變花朵的基本色調。
  2. **學習率排程器**：這是我做出最關鍵的升級之一。我將原本的 CosineAnnealingLR 換成了 **CosineAnnealingWarmRestarts**。從 TABLE II 可以清楚看到，橘色的驗證集準確率呈現非常漂亮的「**階梯式上升**」。每一次學習率的「重啟」(Restart)，都像給模型注入了新的活力，讓它成功跳出局部最佳解，去衝擊下一個準確率高峰。
  3. **耐心與毅力**：根據之前的經驗，我意識到這個模型是「慢熱型」選手。因此，我大膽地將訓練週期拉長到了 **3815 個 epochs**。正是這份耐心，讓我在第 **3400** 個 epoch 附近，迎來了 **92.0%** 的高峰，為後續的半監督學習打下了堅實的基礎。

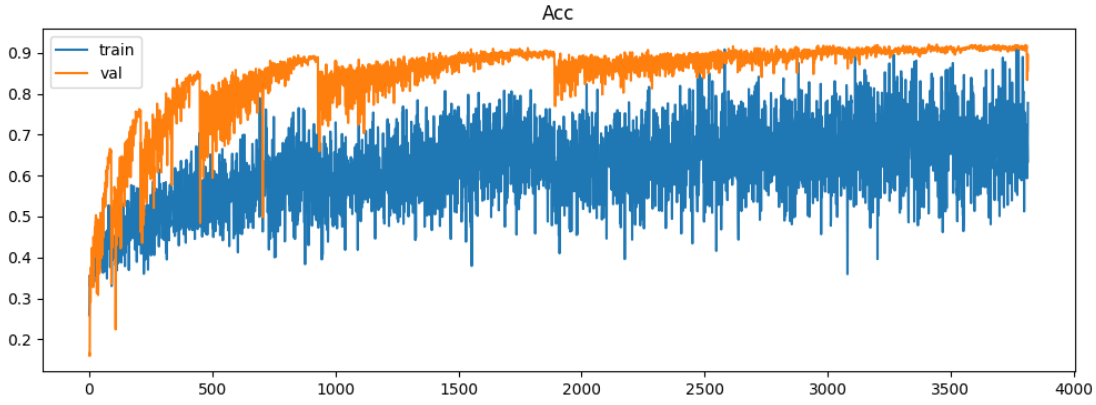

TABLE II : ResNet-34 + WarmRestarts_LR 模型之訓練與驗證準確率曲線

階段二：半監督學習(Final Acc: 0.926)

有了 0.92 的超強 baseline，我遇到了新的挑戰，模型已經太強了，以至於對於剩下大部分未標註的「難題」，它很難產生足夠高的信心（例如 >95%）

來進行標註，導致前幾次嘗試都因加入的樣本過少而「空轉」。

為了解決這個問題，我設計並實作了**最終**的半監督微調策略：

- **動態閾值 (Dynamic Threshold)**：我不再使用固定閾值，而是設計了一個從相對寬鬆的 0.80 開始，隨著訓練進行而逐步變嚴格（最高到 0.95）的動態標準。這讓模型在初期可以先從「相對有把握」的未標註資料中學習，增強自身能力後，再去挑戰更困難的樣本。
- **Top-K 精準滴灌**：結合動態閾值，我還加入了 top_k=100 的限制。這確保了每一輪只加入固定數量的、最高品質的「菁英樣本」，避免了初期因標準相對寬鬆而一次性引入過多潛在雜訊的風險。
- **大膽微調**：有了高品質的新資料，我將學習率設定在 4e-5，並再次使用帶有頻繁重啟 (T_0=20) 的 CosineAnnealingWarmRestarts 排程器，給予模型足夠的動力去吸收新知識並探索新的最佳解。

```
[001/120] saving model with acc 0.906

[002/120] saving model with acc 0.909

[003/120] saving model with acc 0.916

[004/120] saving model with acc 0.917

[005/120] saving model with acc 0.919

[009/120] saving model with acc 0.925

==================== Epoch 10/120 ====================
Train Acc: 0.630000 | Train Loss: 0.712621
  Val Acc: 0.923304 |   Val Loss: 0.486768 | LR: 0.000023
Dataset Size: 1300 (original: 1200, pseudo: 100)
```

```
[037/120] saving model with acc 0.926
```

最終成果： 此策略取得了成功！從最終的訓練日誌可以看到，模型在半監督學習的第 9 個 epoch 就衝上了 92.5%，並在第 37 個 epoch 達到了 92.6% 的驗證集準確率新高。最終提交到 Kaggle，更是取得了 93.23% 的成績。

三、 激活函數的選擇與分析

在深度神經網路中，激活函數扮演著引入非線性特徵的關鍵角色，其選擇

對模型的收斂速度與最終效能有著直接影響。為此，在本專案的初期探索階段，我針對三種主流的激活函數——ReLU、Leaky ReLU 與 GELU——進行了效能比較實驗，以找出最適合本花卉分類任務的架構。

為確保比較公平，我採用了相同的 ResNet-34 基礎架構，並在固定的超參數下（例如，初始學習率 1e-3，AdamW 優化器），分別替換模型中的激活函數，進行了為期約 300 個 epochs 的初步訓練。評估指標主要為驗證集準確率（Validation Accuracy）的收斂速度與最終穩定值。

激活函數	數學形式	理論優點	實驗觀察
ReLU（最終採用）	$f(x) = max(0,x)$	計算速度最快；有效緩解梯度消失問題，收斂迅速。	在本次實驗中，ReLU 在訓練初期展現了**最快的收斂速度**，準確率曲線 能夠在最短時間內達到一個較高的水平。
Leaky ReLU	$f(x) = max(\alpha x,x)$	為負數輸入提供了一個微小的非零梯度。	Leaky ReLU 的收斂曲線較為平緩，並未在本任務的初期訓練中展現出顯著的優勢。雖然理論上更穩健，但在這個資料集上似乎沒有帶來額外的效能提升。
GELU（高斯誤差線性單元）	$f(x) = x \cdot \Phi(x)$	更平滑的非線性函數，被證明在許多先進的 Transformer 模型中表現優異。	GELU 的計算成本相對較高，訓練速度稍慢。在本次實驗中，其初期表現與 Leaky ReLU 相似，沒有超越標準 ReLU 的收斂速度。

綜合初步的實驗結果與理論分析，我做出如下決策：

ReLU 在本次花卉分類任務中，展現了**最佳的成本效益比**。它不僅計算效率最高，而且收斂速度最快，能夠讓模型在最短時間內學習到有效的影像特徵。雖然 Leaky ReLU 和 GELU 在理論上解決了 Dying ReLU Problem，但在本次的

初步實驗中，這些優勢並未轉化為實際的效能增益。考量到專案的核心挑戰在於**處理小樣本資料的過擬合問題**（這主要透過後續的強力資料增強和半監督學習來解決），因此，在激活函數的選擇上，我決定採用最成熟、最標準化且初期收斂最快的 ReLU。

四、 結論

這次模型的結果並非一蹴可幾，而是試錯與迭代的過程。從最初的 ResNet-50，到中間探索的 ConvNeXt，再到最終版的 ResNet-34 ，每一步都為最終的結果奠定了基礎。

最終的 0.9323 準確率，歸功於以下幾個策略的結合：

1. **架構選擇**：ResNet-34 在此任務上展現了最佳的適應性。
2. **極致的正規化**：強力的資料增強與 Mixup/CutMix 是對抗過擬合、提升泛化能力的基石。
3. **訓練策略**：長週期的訓練搭配 CosineAnnealingWarmRestarts，是壓榨模型潛力的關鍵。
4. **精準的半監督學習**：動態閾值結合 Top-K 的「精準滴灌」策略，是突破瓶頸、完成最後一哩路的拼圖。

這次的經驗讓我深刻體會到，深度學習不僅僅是選擇最強的模型，更是要根據具體任務，系統性地設計和驗證一整套從資料、訓練到微調的完整策略。